Seminarski rad:

Analiza i implementacija mikroskopskog modela gužve s cellular automata pristupom

Mislav Marinović

Mentor: izv. prof. dr. sc. Mario Bukal

25. svibnja 2026.

Sveučilište u Zagrebu
Fakultet elektrotehnike i računarstva

Motivacija

- Događaji koji očekuju veliki broj ljudi su sigurnosni rizici
- Pri visokim gustoćama ljudi nekontrolirana kretnja može rezultirati situacijama nazvanim **crowd-crush**
- Primjeri:
  - Hillsborough disaster 1989.
  - Astroworld tour 2021.
  - Seoul Halloween crowd crush 2022.



Motivacija

- Razvoj modela dinamike velikog broja ljudi i sigurnosne analize prostora zahtijevaju realistične simulacije kretanja
- Ručno modeliranje matematički je iscrpno u složenim scenarijima evakuacije
- Zbog toga su algoritmi za simulaciju gibanja i zagušenja u kretnji ljudi važna i korisna tema u računalnom modeliranju i analizi sigurnosti prostora

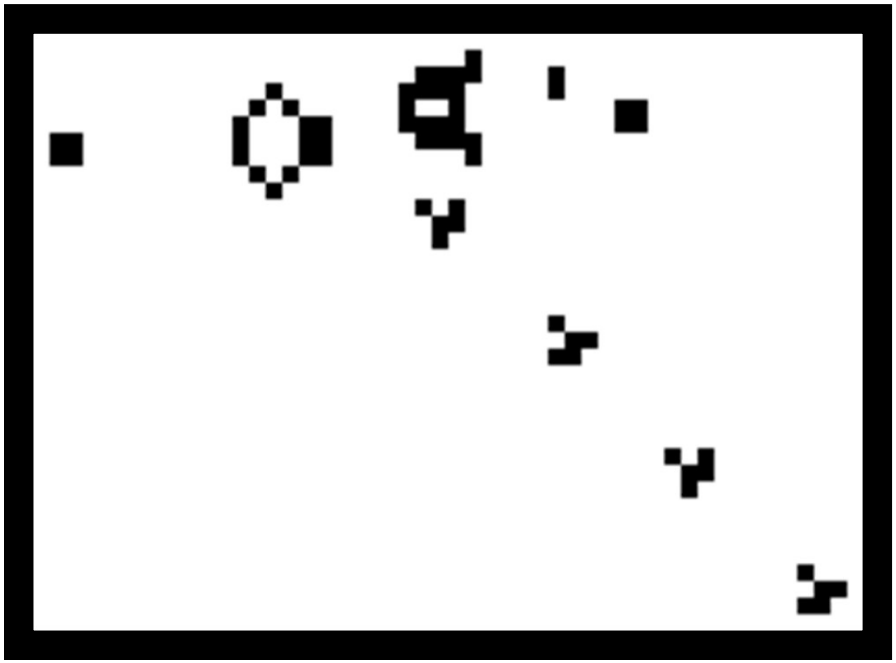
O radu

- **Cilj rada:** ostvariti računalni model simulacije gibanja velikog broja ljudi i prikaza crowd-crush situacija
  - proučiti utjecaj **geometrije prostora** i ponašanja agenata na protočnost sustava

- Implementacija izvedena korištenjem **cellular automata** pristupa i agentnog modeliranja u Pythonu
  - biblioteka **Mesa** [3] korištena za modeliranje simulacije bazirane na agentima

Cellular automata

- Prostor podijeljen na **diskretnu mrežu ćelija**
  - Agent, slobodan prostor, prepreka ili izlaz
- Agenti se gibaju prema unaprijed definiranim lokalnim pravilima
- Složeno ponašanje nastaje kao posljedica velikog broja lokalnih interakcija

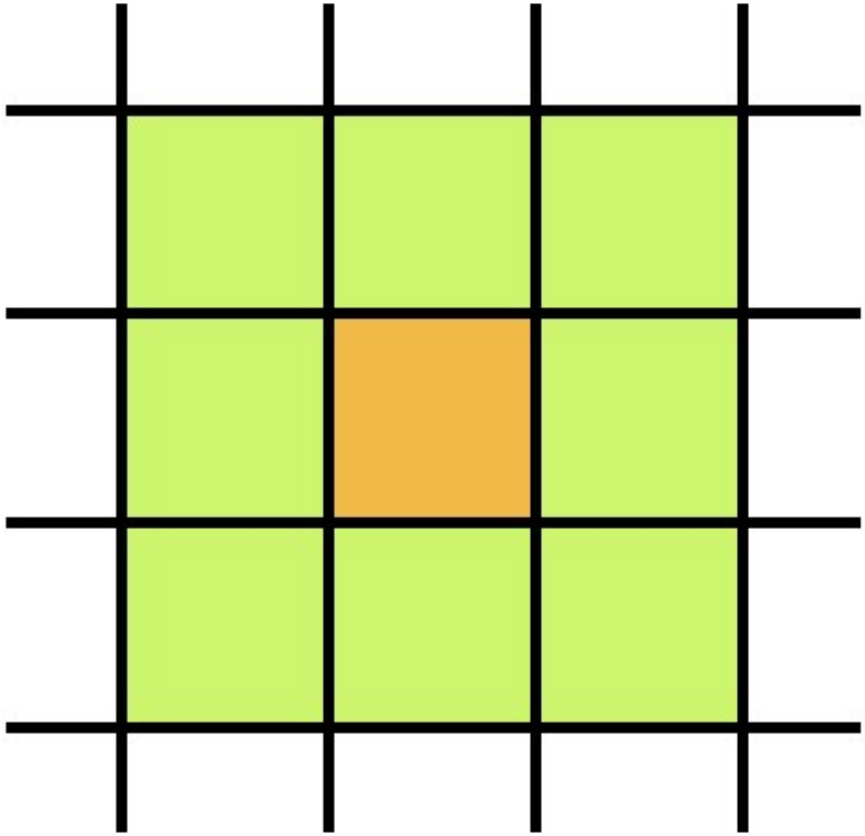


Conway's "Game of Life"

Definiranje modela simulacije

- U diskretni prostor postavimo određenu količinu agenata
- Kretnja je određena evaluacijom statičkog polja udaljenosti do izlaza, lokalne gustoće ciljane ćelije i utjecaja prepreka u okolini

$$P_i = \frac{Score_i}{\sum_j Score_j}$$



*Za pregled prostora, koristimo **Mooreovu** okolinu*

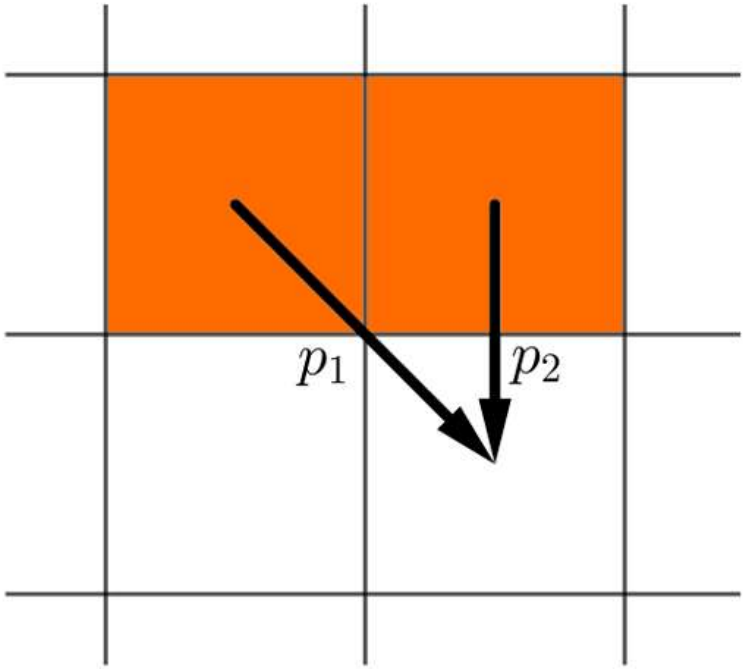
Definiranje modela simulacije

- Tijekom trajanja simulacije česta je pojava da dva agenta žele zauzeti istu poziciju

- Ovakvi konflikti se mogu rješavati na više načina
  - Koristimo nasumično biranje pobjedničkog agenta

    $P(agent\ X = 1\ će\ se\ pomaknuti) = \frac{1}{n}$
  - U referentnom radu [1] , koristi se zbrajanje vjerojatnosti odabira

    $P(agent\ X = 1\ će\ se\ pomaknuti) = \frac{p_1}{p_1 + p_2}$



Preuzeto iz referentnog rada

Parametri modela

- Pri evaluaciji kretnje koristimo kombinaciju parametara

$$Score = kS \cdot S - kD \cdot D - kO \cdot O$$

- kS
  - S – **statičko polje udaljenosti do izlaza**, definirano na početku pomoću BFS pretraživanja (Manhattanova udaljenost)
    - Pomoću parametra definiramo koliko najbrži izlaz se uzima kao faktor pri evaluaciji idućeg poteza
- kD
  - D – **lokalna gustoća ćelije**
    - koliko agent uzima u obzir količinu agenata u ćeliji
- kO
  - O – **polje odbojnosti od prepreka**
    - definiramo koliko se agenti drže razmaka od zida

Parametri modela

- Pomoću parametara modeliramo moguće scenarije evakuacije
  - kS i kD su obrnuto proporcionalni, veći kS i manji kD ukazuju na žurniji bijeg prema izlazu uz manje obzira na količinu ljudi na putu
  - Suprotna situacija implicira sporiju kretnju prema izlazu i manje naguravanja

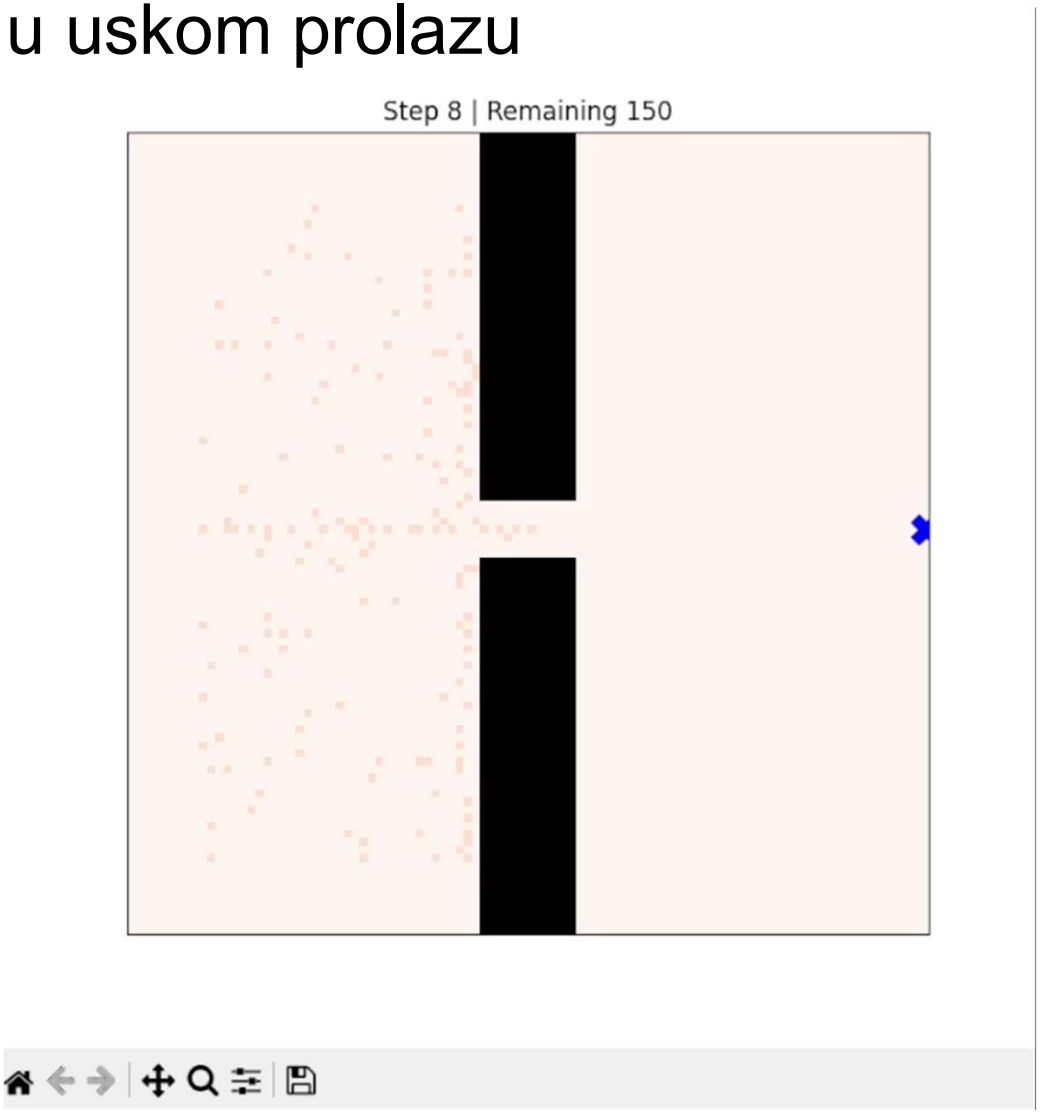
- kO je poseban faktor, modeliran pomoću Gaussove funkcije

$$O(x,y) = e^{-\frac{d^2(x,y)}{2\sigma^2}}$$

d je udaljenost ćelije od prepreke, a σ je parametar širine utjecaja

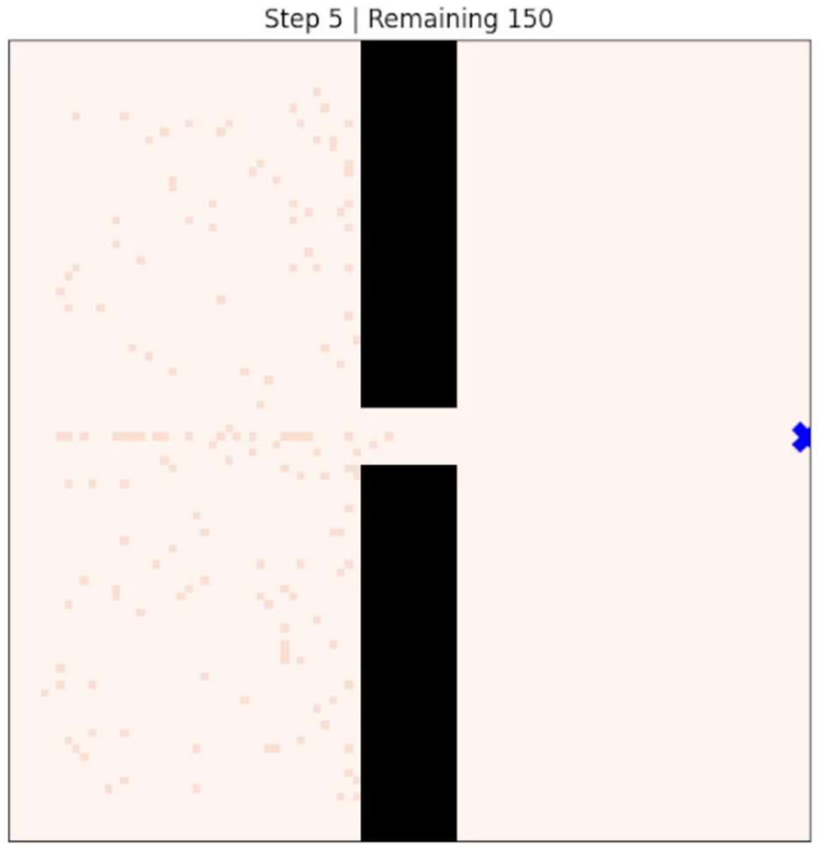
Rezultati – analiza parametara

- U situaciji gdje je kD veći od kS, kretanje je mirnije bez problema u uskom prolazu

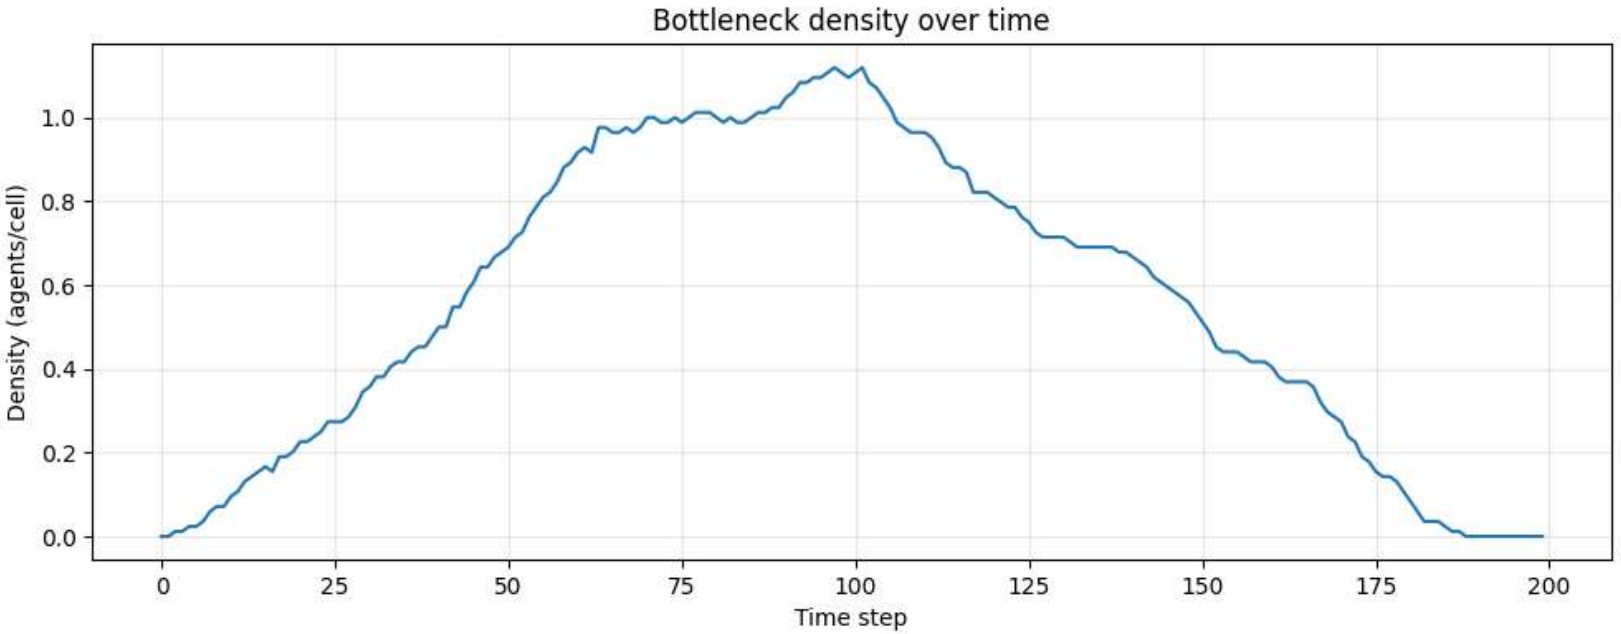


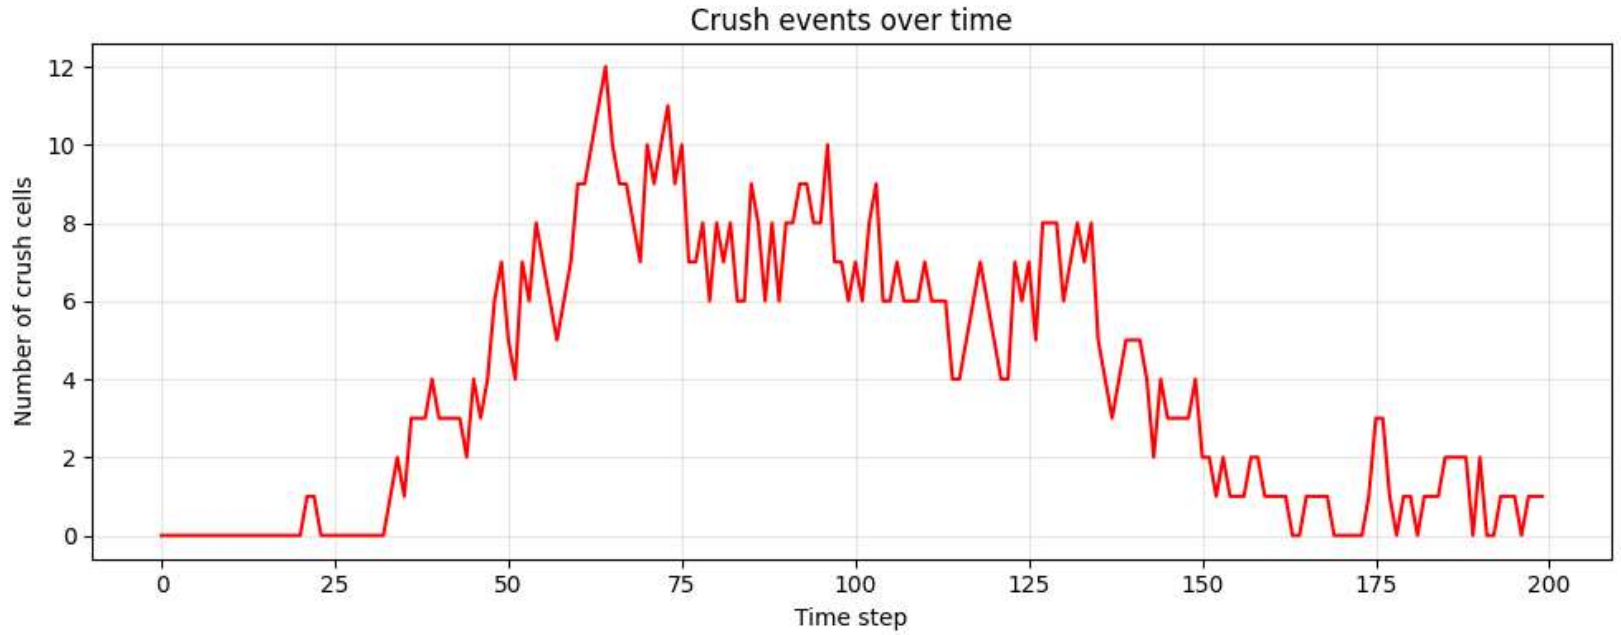
Rezultati – analiza parametara

- Ponovimo situaciju sa većim kS i manjim kD, primijetimo da se stvaraju karakteristični problemi



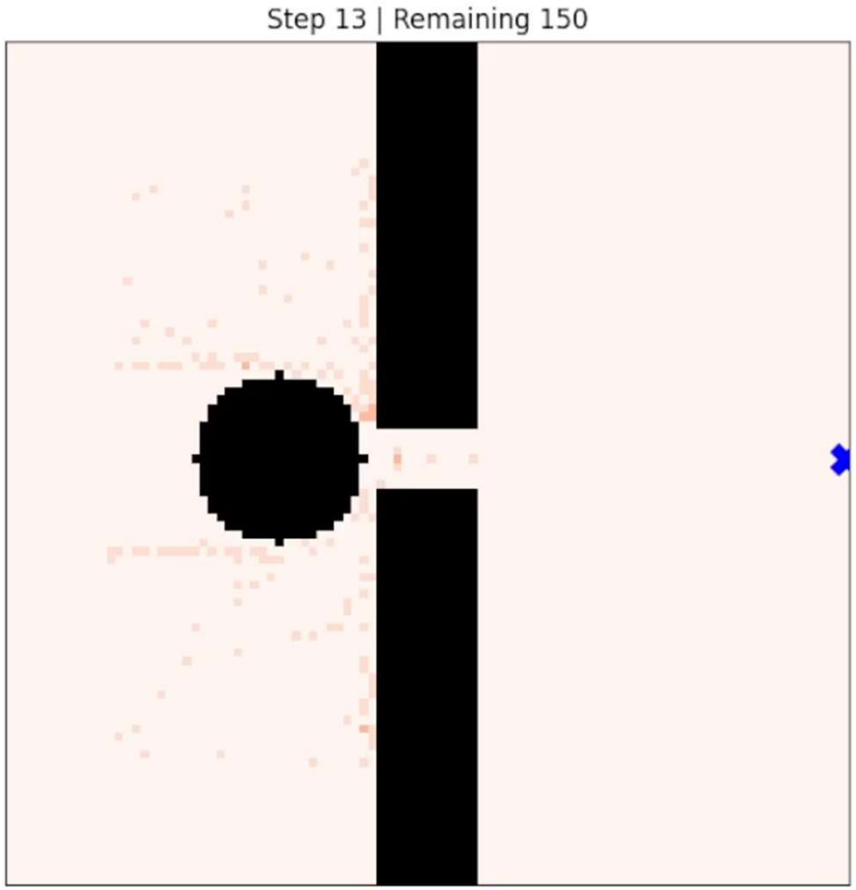
Rezultati – analiza parametara





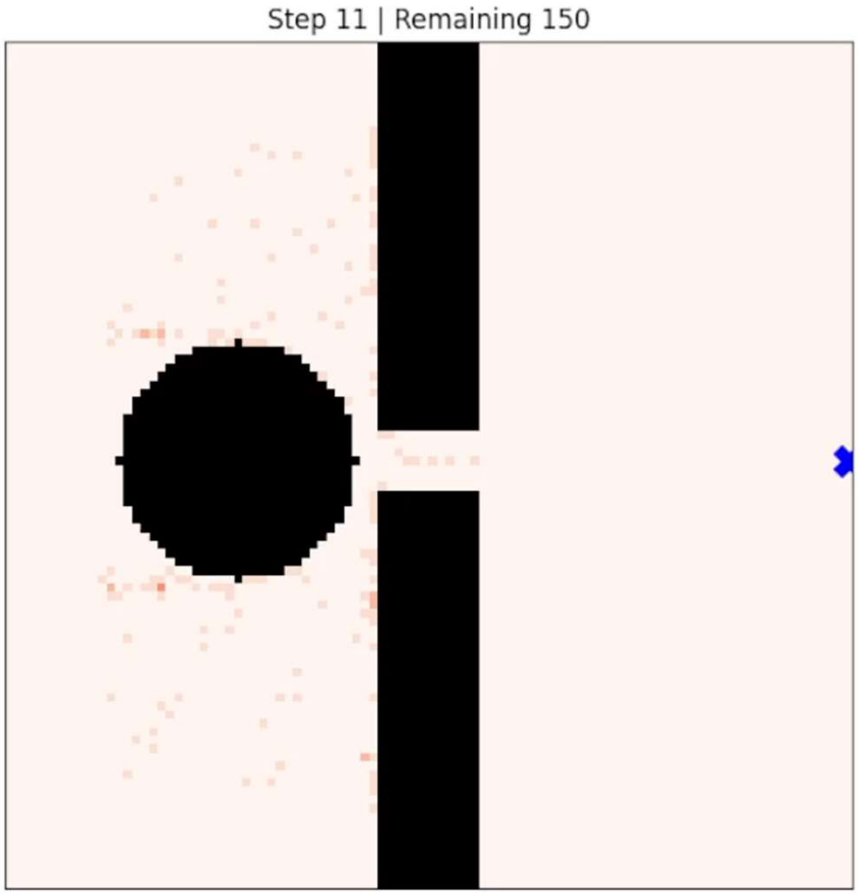
Rezultati – Analiza geometrije

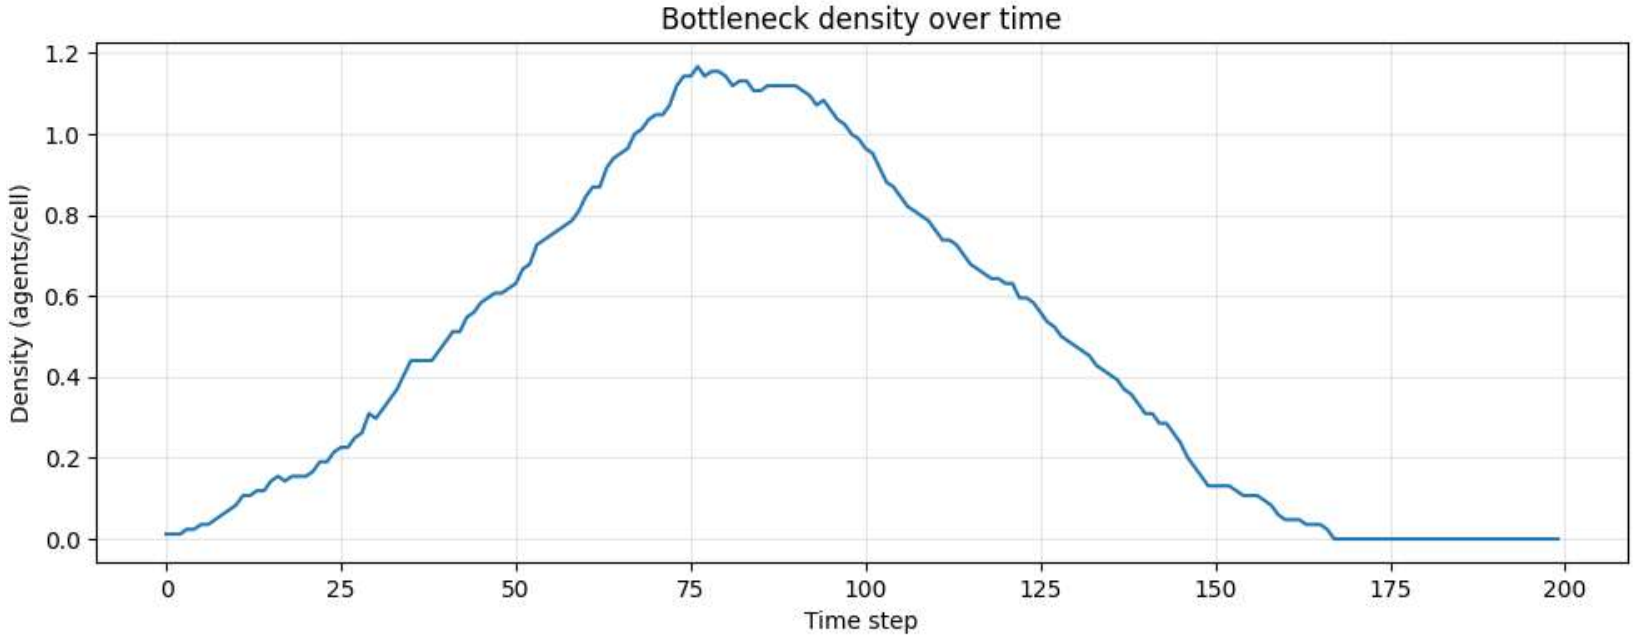
- Ako je koridor uži, stanje se pogoršava
- Može li dodavanje prepreke pomoći u kontroliranju prolaska?

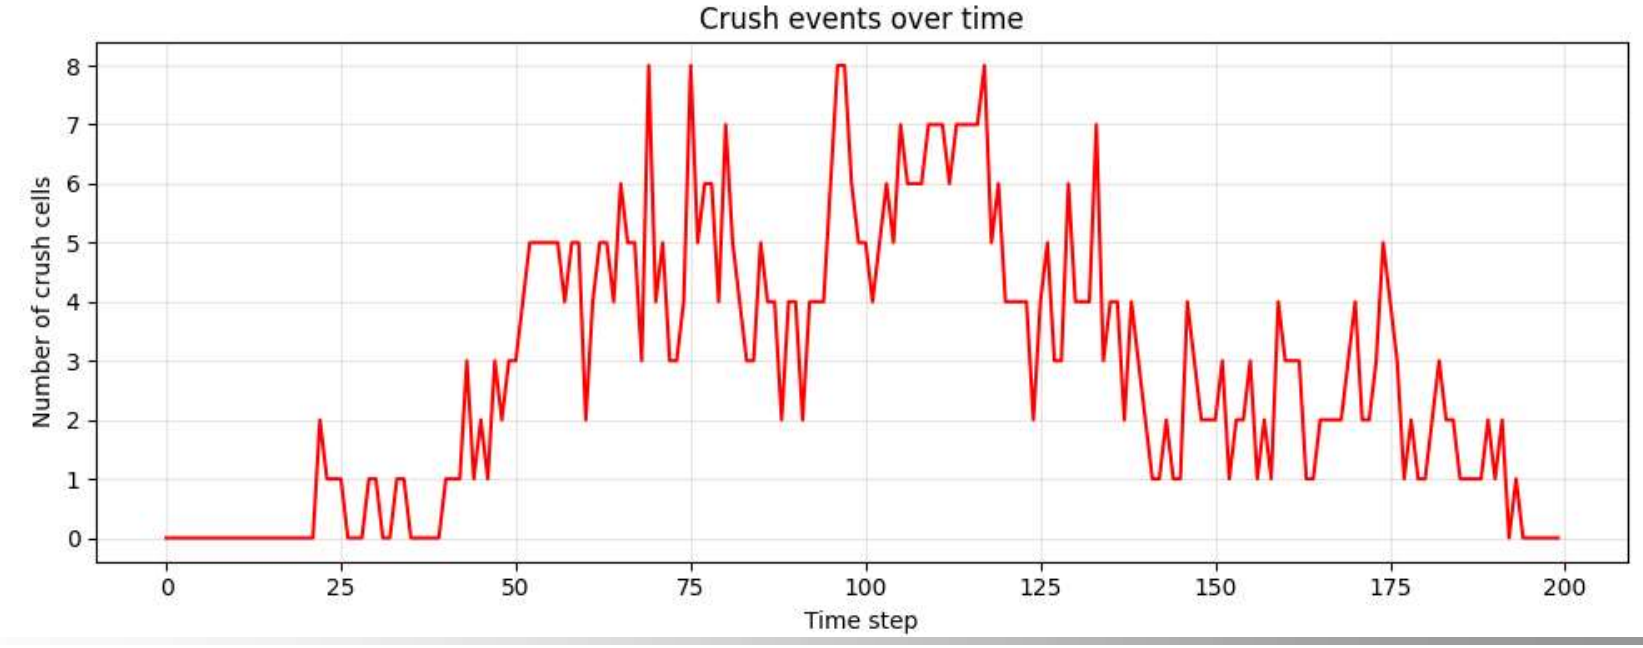


Rezultati – Analiza geometrije

- Rezultat ponavljamo s većom preprekom




Bottleneck density over time
Density (agents/cell)
1.2
1.0
0.8
0.6
0.4
0.2
0.0
0
25
50
75
100
125
150
175
200
Time step


Crush events over time
Number of crush cells
8
7
6
5
4
3
2
1
0
0
25
50
75
100
125
150
175
200
Time step

Zaključak

- Parametri efektivno prikazuju različita stanja krize i kako s većom žurnošću povećavamo broj crowd-crush događaja

- Iako neoptimalna, okrugla prepreka implicira što je cilj rješavanja problema – **prostorna disperzija** agenata **prije** ulaska u uski prolaz.
  Time se postiže razdvajanje vremenskih trenutaka ulaska u koridor, ovisno o početnoj poziciji agenata, što smanjuje simultano opterećenje uskog područja.

- U praksi, koristimo prepreke koje kontroliraju tok kretnje, smanjujući vjerojatnost lokalnih preopterećenja i omogućujući sigurniji prolaz kroz kritične dijelove

Literatura

[1] Fischer Michael, Jankowiak Gaspard, And Wolfram Marie-therese *Micro- And Macroscopic Modeling Of Crowding And Pushing In Corridors, 2020.*

[2] Wolfram Mathworld, *Cellular Automaton* Link: https://mathworld.wolfram.com/CellularAutomaton.html

[3] Mesa: Agent-based modeling in Python, [Mrežno]. Available: https://mesa.readthedocs.io/stable/