SVEUČILIŠTE U ZAGREBU

FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

SEMINAR

Analiza i implementacija mikroskopskog modela gužve s cellular automata pristupom

Mislav Marinović

Voditelj: *Izv. prof. dr. sc. Mario Bukal*

Zagreb, travanj, 2026

Sadržaj

1. Uvod 1
2. Mikroskopski modeli 2
3. Cellular automata 3
4. Pravila kretnje 4
5. Implementacija 6
6. Analiza rezultata 10
7. Zaključak 15
8. Sažetak 16
9. Literatura 17

1. Uvod

Upravljanje velikim skupinama ljudi je problem u modernome društvu za koji se aktivno razvijaju rješenja i novi pristupi. Neadekvatno razumijevanje dinamike kretanja mase ljudi može dovesti do opasnih situacija, uključujući i katastrofalne scenarije poput pojave „*crowd crush*" efekta [1]. Zbog toga se razvijaju različiti modeli i metode kojima je cilj analizirati i predvidjeti ponašanje ljudi u uvjetima velike gustoće.

Jedan pristup modelu gužvi je temeljen na mikroskopskoj analizi, pri kojoj se svaki pojedinac promatra kao zaseban agent s vlastitim pravilima kretanja i interakcije. Takvi modeli omogućuju detaljniji uvid u kolektivno ponašanje mase, jer složeni sustavi proizlaze iz jednostavnih lokalnih interakcija među agentima.

Mikroskopskoj analizi možemo pristupiti koristeći nekoliko metoda, jedna od kojih je cellular automata. Cellular automata prostor modelira kao diskretnu mrežu ćelija čije stanje ovisi o susjednim ćelijama.

Analizirati ćemo implementaciju ponuđene metode kroz računalnu simulaciju, koja omogućuje vizualizaciju kretanja velikog broja ljudi u ograničenom prostoru. Cilj je reproducirati i proučiti rezultate prikazane u odabranom znanstvenom članku, te kroz njih procijeniti učinkovitost modela u detekciji potencijalno opasnih situacija i razumijevanju dinamike gužvi. Na taj način doprinosi se boljem planiranju prostora i povećanju sigurnosti u uvjetima visoke koncentracije ljudi.

2. Mikroskopski modeli

Mikroskopski modeli predstavljaju matematički i računalni pristup modeliranju gibanja velike mase ljudi. Osnovna karakteristika takvih modela jest da se agent u sustavu promatra kao zaseban entitet s vlastitim položajem i pravilima interakcije s okolinom i drugim agentima. Za modeliranje evakuacije i nastanka opasnih situacija poput „*crowd crush*" efekta, mikroskopski modeli su korisni jer omogućuju analizu lokalnih interakcija među pojedincima i gdje i kako nastaju točke zagušenja, konflikata pri kretanju i procesa fizičkog potiskivanja u područjima visoke gustoće.

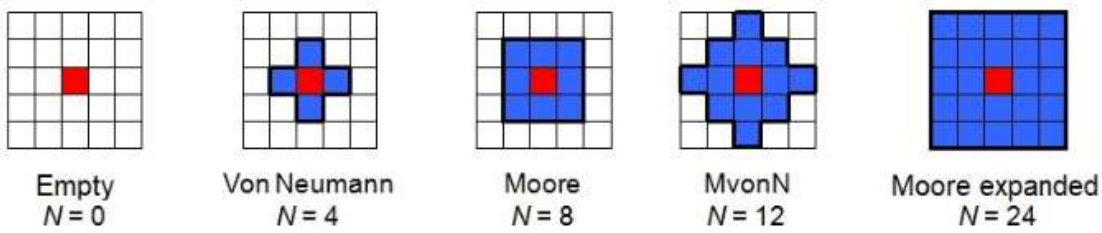
Kod mikroskopskog pristupa sustav se sastoji od konačnog broja agenata koji se gibaju unutar diskretnog ili kontinuiranog prostora prema unaprijed definiranim pravilima. Svaki agent donosi odluku o kretanju na temelju lokalnih informacija poput udaljenosti od izlaza, prisutnosti drugih agenata, prisutnosti prepreka u prostoru i slično. Time se globalno ponašanje ne definira izravno, nego nastaje kao posljedica velikog broja lokalnih interakcija između agenata. Sa ovakvim pristupom ostvarujemo kretnju i imamo uvid u to kako se u prostoru stvaraju trake gibanja, zastoji i pratiti gustoću sustava.

Kao glavni izvor za ovaj seminar, usmjerujemo se u „*Micro- and macroscopic modeling of crowding and pushing in corridors*" [2]. Rad proučava ponašanje ljudi u koridorima pri visokim gustoćama koristeći istovremeno mikroskopske i makroskopske modele. Poseban naglasak stavljen je na modeliranje procesa naguravanja (engl. „*pushing*") u situacijama povećane motivacije za izlazak. U radu se definira osnovni prvi parametar koji ćemo pregledavati u ovome radu, a to jest motivacija agenata da dođu do izlaza. Što je agent više motiviran doći do izlaza, to je mogućnost dešavanja naguravanja veća. U mikroskopskom dijelu rada koristi se diskretni model temeljen na pojedinačnim agentima i pravilima lokalnog gibanja. Agent zauzima određeni položaj unutar prostora te u svakom vremenskom koraku odlučuje o mogućem pomaku prema izlazu. Smjer gibanja određen je kombinacijom željenog smjera kretnje, dostupnosti pozicija i parametra motivacije.

Potrebno je naglasiti dostupnost pozicija jer s njome dolazimo do prve prepreke u definiranju pravila, a to je rješavanje konflikta. Kada više agenata pokušava zauzeti isti prostor, dolazi do konflikta koji se razrješava određenim pravilima prioriteta ili slučajnim odabirom. Upravo takvi konflikti predstavljaju osnovni mehanizam nastanka lokalnog zagušenja i povećanja gustoće agenata. U uvjetima niske gustoće navedeni konflikti uglavnom ne predstavljaju značajan problem jer sustav posjeduje dovoljan broj slobodnih pozicija koje agenti mogu zauzeti bez većih međusobnih interakcija. Međutim, povećanjem gustoće populacije dolazi do progresivnog smanjenja broja dostupnih ćelija i povećanja frekvencije konflikata među agentima. U takvim uvjetima ponašanje sustava prelazi iz relativno slobodnog toka u stanje lokalnog zagušenja pri kojem kretanje pojedinaca postaje izrazito ovisno o ponašanju neposredne okoline. U takvim okolnostima se pojavljuju događaji karakteristični za stvarne mase ljudi, poput formiranja polukružnih zona visoke gustoće ispred izlaza, spontanog nastanka uskih grla te pojave oscilacija u protoku ljudi kroz prolaze ograničenog kapaciteta.

3. Cellular automata

Cellular Automata je jedan od načina modeliranja mikroskopskog rješenja. Takvi modeli prostor promatraju kao diskretnu mrežu ćelija unutar koje se agenti gibaju prema unaprijed definiranim pravilima prijelaza. Svaka ćelija može predstavljati slobodan prostor, prepreku, izlaz ili poziciju zauzetu agentima. Vrijeme se također promatra diskretno, pri čemu se stanje sustava ažurira u uzastopnim vremenskim koracima. Ideja cellular automate temelji se na činjenici da se složeno kolektivno ponašanje može dobiti primjenom jednostavnih lokalnih pravila. U svakom vremenskom koraku agent analizira svoju neposrednu okolinu te na temelju dostupnih informacija određuje potencijalni smjer gibanja. Odluka o kretanju najčešće ovisi o udaljenosti do izlaza, prisutnosti drugih agenata, dostupnosti susjednih ćelija i parametrima motivacije sustava [3].



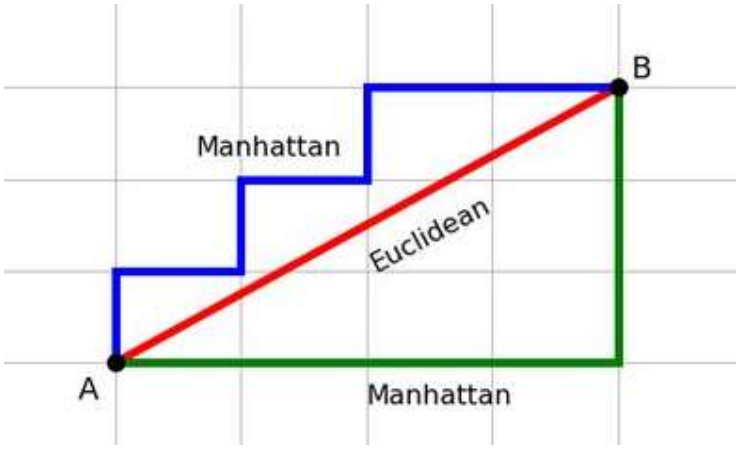
Sl. 3.1 Metode pregleda susjedstva. Preuzeto sa Web članka

Dakle, cellular automata sastoji se od diskretnog prostora podijeljenog na ćelije, konačnog skupa mogućih stanja ćelija i skupa pravila prijelaza kojima se određuje promjena stanja sustava kroz vrijeme. Stanje pojedine ćelije u sljedećem vremenskom koraku ovisi o trenutačnom stanju same ćelije i stanju ćelija unutar definirane okoline. U dvodimenzionalnim sustavima najčešće se koriste Von Neumannova i Mooreova okolina, koje definiraju skup susjednih ćelija dostupnih agentu pri donošenju odluke o kretanju.

U području modeliranja kretnje mase ljudi cellular automata modeli koriste se za simulaciju procesa evakuacije, analizu protočnosti prostora i proučavanje nastanka naguravanja pri velikim gustoćama populacije. Diskretna priroda modela omogućuje precizno praćenje interakcija među agentima, pojave konflikata pri kretanju i formiranja lokalnih zona povećane gustoće. Takve karakteristike posebno su važne pri proučavanju fenomena poput blokiranja prolaza, stvaranja uskih grla i pojave „crowd crush" efekta. U nastavku rada, cellular automata koristit će se kao temeljni mikroskopski model za simulaciju gibanja agenata unutar zatvorenog prostora s definiranim izlazima.

4. Pravila kretnje

Kada smo definirali model i metodu izvoda, moramo definirati i kako će agenti sustava se gibati. Pravila kretnje predstavljaju temeljnu komponentu modela jer određuju način interakcije agenata s okolinom, drugim agentima i geometrijom prostora. Svaki agent tijekom pojedinog vremenskog koraka promatra svoju neposrednu okolinu i određuje potencijalnu novu poziciju. Kretanje je ograničeno na susjedne ćelije koje predstavljaju dostupne smjerove gibanja, dok se ćelije koje predstavljaju prepreke ili zidove ne mogu zauzeti. Prilikom donošenja odluke o kretanju agent evaluira svaku dostupnu susjednu ćeliju koristeći kombinaciju više parametara koji opisuju kvalitetu pojedine pozicije. Temeljni parametar predstavlja statičko polje udaljenosti koje određuje udaljenost pojedine ćelije od izlaza. Statičko polje računa se unaprijed za cijeli prostor te svakom agentu omogućuje određivanje poželjnog smjera gibanja prema izlazu. Ćelije koje se nalaze bliže izlazu imaju povoljniju vrijednost polja, zbog čega agenti prirodno preferiraju gibanje u njihovom smjeru. Metoda za računanje udaljenosti do izlaza je Manhattan metoda, prikazana na slici 4.1.



Sl. 4.1 Manhattanova udaljenost u odnosu na Euklidsku

Osim udaljenosti do izlaza, pri donošenju odluke uzima se u obzir i lokalna gustoća sustava. Agent evaluira broj drugih agenata koji se nalaze unutar potencijalne ciljne ćelije. Ćelije s većom lokalnom gustoćom imaju manju vjerojatnost odabira jer predstavljaju područja povećanog naguravanja i smanjene brzine kretnje. Odluka o tome hoće li agent pristupiti ćeliji sa drugim agentima je definirana parametrom koji daje agentima volju za naguravanje.

Dodatni element modela predstavlja polje odbojnosti prepreka. U blizini zidova, prepreka i geometrijskih suženja agentima se pridružuje negativna vrijednost koja smanjuje vjerojatnost odabira takvih pozicija. Navedeni pristup omogućuje modeliranje prirodnog izbjegavanja prepreka i održavanja određene udaljenosti od granica prostora. U implementaciji se utjecaj prepreka modelira korištenjem Gaussove funkcije čiji intenzitet opada povećanjem udaljenosti od prepreke.

$$O(x,y) = e^{-\frac{d^2(x,y)}{2\sigma^2}}$$

1 Polje odbojnosti. d(x,y) je udaljenost ćelije od prepreke, a σ je parametar širine utjecaja

Često se dešava situacija da određena ćelija bude meta više agenata. Ovi konflikti su važan dio prikaza kretnje i način na koji se rješavaju utječe na protočnost sustava. U takvim situacijama nije moguće istovremeno premjestiti sve agente na istu poziciju, zbog čega model koristi pravila razrješavanja konflikta. U implementiranom sustavu konflikt se razrješava slučajnim odabirom jednog agenta kojemu je dopušteno zauzimanje ciljne ćelije, dok ostali agenti ostaju na svojim prethodnim pozicijama. U prostorima sa puno konflikata krenu se stvarati karakteristični problemi gibanja velike mase ljudi, visoke gustoće ljudi, naguravanja i smanjenje protočnosti.

Uz pravila kretnje treba razjasniti unutarnje parametre svih agenata s kojima možemo bolje opisati moguće scenarije kretnje. Svaki agent pri donošenju odluke o pomaku računa vrijednost funkcije procjene za sve dostupne susjedne pozicije. Ukupna vrijednost pojedine ćelije određena je izrazom:

$$Score = \mathrm{kS} \cdot \mathrm{S} - \mathrm{kD} \cdot \mathrm{D} - \mathrm{kO} \cdot \mathrm{O}$$

Gdje *S* Predstavlja vrijednost statičkog polja udaljenosti od izlaza, *D* je lokalna gustoća te *O* je utjecaj prepreke zidova. Uz te vrijednosti nalaze se skalari odnosno parametri pomoću kojih definiramo koliko koja vrijednost ima utjecaja na konačni rezultat odluke.

Parametar *kS* određuje jačinu utjecaja statičkog polja udaljenosti na ponašanje agenata. Povećanjem vrijednosti parametra *kS* agenti snažnije preferiraju najkraći put prema izlazu. Kod velikih vrijednosti parametra agenti gotovo deterministički prate smjer minimalne udaljenosti prema izlazu. Posljedica toga može biti povećano grupiranje agenata oko optimalnih putanja i intenzivnije stvaranje zagušenja u područjima uskih prolaza.

Parametar *kD* određuje utjecaj lokalne gustoće. Vrijednost *D* određena je brojem agenata prisutnih unutar potencijalne ciljne ćelije. Osnovna funkcija ovog parametra jest modeliranje želje agenata da izbjegavaju područja visoke gustoće. Veće vrijednosti parametra *kD* povećavaju osjetljivost agenata na prisutnost drugih sudionika sustava, no znatno usporavaju žurnost izlaza jer agenti čekaju da se ispred njih oslobodi dovoljno prostora za kretnju.

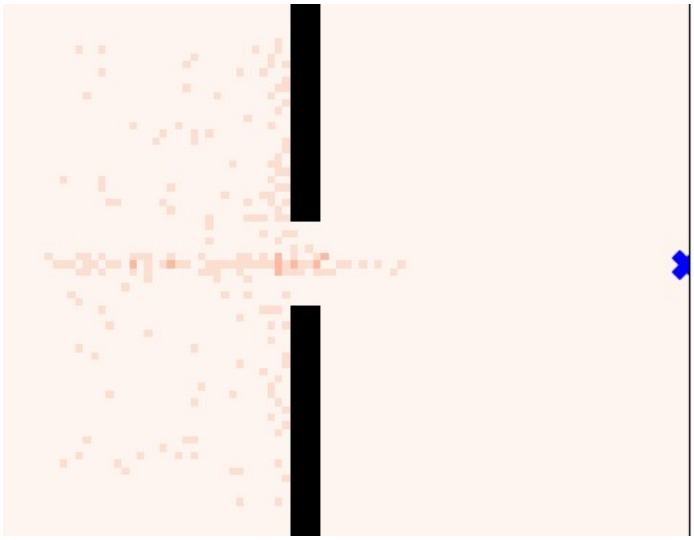
Parametar *kO* određuje jačinu utjecaja prepreka i zidova na ponašanje agenata. Vrijednost O dobiva se iz polja odbojnosti prepreka koje modelira želju agenata da održavaju određenu udaljenost od prepreka i granica prostora.

Međusobni odnos ovih parametra znatno mijenja konačan ishod simulacije i količinu naguravanja i crowd crush događaja koji su se desili. Na primjer, visoke *kS* i niske *kO* stvaraju više kaotične i brže izlaze sa puno naguravanja, dok niske *kS* i visoke *kO* daju mirniji izlaz sa niskim faktorom rizika.

5. Implementacija

Simulacijski model izveden je u programskom jeziku Python korištenjem mikroskopskog pristupa temeljenog na cellular automata modelu. Za implementaciju modela korišteno je nekoliko standardnih Python biblioteka. *Numpy* koristi se za rad s matricama, numeričke operacije i pohranu prostornih polja sustava. *Matplotlib* koristi se za vizualizaciju simulacije, prikaz gustoće agenata i grafičku analizu rezultata. *Collections.deque* koristi se za učinkovitu implementaciju BFS algoritma prilikom računanja statičkog polja udaljenosti. *Mesa* biblioteka za agentno modeliranje koja omogućuje upravljanje agentima, mrežom prostora i izvođenjem simulacijskih koraka [4]. Korištenjem biblioteke *Mesa* implementiran je agentni sustav unutar kojeg svaki agent posjeduje vlastitu logiku ponašanja i mogućnost neovisnog donošenja odluka tijekom simulacije.

Sam prostor modeliran je kao dvodimenzionalna kvadratna mreža sa unaprijed određenim brojem ćelija. Ćelija može reprezentirati slobodan prostor, prepreku, izlaz ili putujućeg agenta (ili njih više). Za pohranu prostora koristi se struktura *MultiGrid* koja omogućuje pohranu više agenata unutar iste ćelije. Sa ovime i ostvarujemo mogućnost pronalaska ćelija pre velikom gustoćom i kritičnih točaka u našem prostoru.



Sl. 5.1 Izgled sustava i agenata u njemu. Količina agenata u točki indicirana je tamnijom crvenom bojom, a izlaz je prikazan sa plavim X

Geometrija prostora definira zidove, prolaze i izlaze sustava. U implementaciji je korišten koridor sa suženjem koje simulira usko grlo. Usko grlo modeliramo po našoj potrebi sa varijabilnim veličinama dužine i širine koridora.



Sl. 5.2 Uži i duži koridor od onoga prikazanog u Sl. 5.1

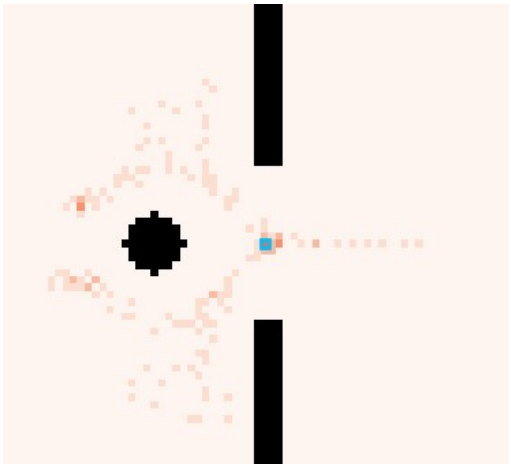
Prije nego što možemo pustiti agentima da se gibaju u prostoru, moramo izračunati statičko polje udaljenosti svih ćelija sustava od izlaza. Statičko polje udaljenosti implementirano je korištenjem BFS algoritma pri čemu je prostor definiran Von Neumannovom okolinom. U takvom pristupu agenti tijekom izračuna udaljenosti mogu napredovati isključivo u horizontalnom i vertikalnom smjeru, zbog čega dobivena udaljenost odgovara Manhattanovoj metrici. Dobiveno statičko polje predstavlja osnovni mehanizam usmjeravanja agenata prema izlazu tijekom simulacije. Svaka ćelija unutar prostora dobiva numeričku vrijednost koja opisuje njezinu udaljenost od izlaza, pri čemu ćelije bliže izlazu imaju povoljnije vrijednosti polja. Tijekom svakog vremenskog koraka agent promatra susjedne ćelije unutar definirane okoline te evaluira njihove vrijednosti statičkog polja zajedno s ostalim parametrima sustava poput lokalne gustoće i prisutnosti prepreka. Takav pristup omogućuje modeliranje kolektivnog gibanja bez potrebe za globalnim upravljanjem sustavom jer svaki agent donosi odluke isključivo na temelju lokalno dostupnih informacija i unaprijed izračunatog polja udaljenosti.

```
while queue:
   x, y = queue.popleft()
   for dx, dy in ((1, 0), (-1, 0), (0, 1), (0, -1)):
      nx, ny = x + dx, y + dy
      if 0 <= nx < GRID_SIZE and 0 <= ny < GRID_SIZE:
          if geometry[ny, nx] == 1 and dist[ny, nx] == np.inf:
                dist[ny, nx] = dist[y, x] + 1
                queue.append((nx, ny))
```

Uz prostor moramo i definirati stvari u njemu, odnosno prepreke. Postavimo ih kao neprolazne ćelije koje se ne uvažavaju za računanje polja udaljenosti (kroz njih se ne može proći). Uz to moramo i definirati odbojnost od tih prepreka, što ćemo napraviti pretvaranjem ranije spomenute formule u kod.

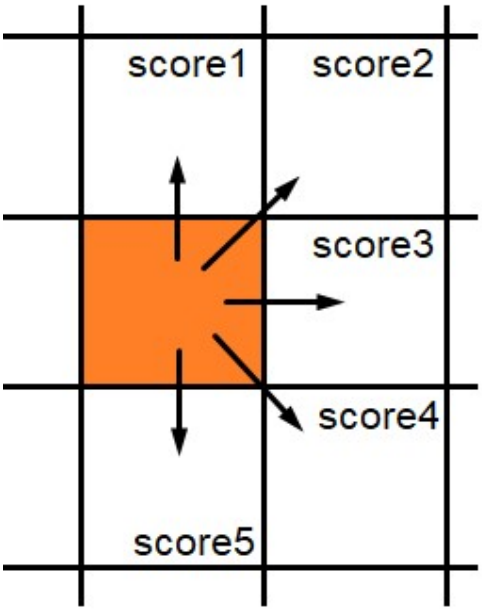
```
field = np.exp(-min_d2 / (2 * OBSTACLE_SIGMA**2))
```

Za dodavanje dodatne prepreke imamo opciju postavljanja okrugle prepreke ispred ulaza u koridor, i vidjeti utjecaj njezin na tok simulacije.



Sl. 5.3 Prikaz velikog izjbjegavanja agenata od prepreka, kO = 30

Svaki agent zasebno računa svoj idući korak promatrajući susjedne ćelije i evaluirajući koja ćelija mu je najprimamljivija. Primamljivost ćelije definirana je kao varijabla Score spomenuta maloprije. Svaka susjedna ćelija ima varijablu Score te se te vrijednosti pozbrajaju i definira se vjerojatnost prelaska na neku drugu ćeliju kao Score te ćelije dijeljeno sa sumom svih susjednih Score-ova. Korištenjem probabilističkog pristupa uvodi se stohastička komponenta sustava, čime se postiže realističnije ponašanje mnoštva i izbjegava potpuno deterministično gibanje agenata.



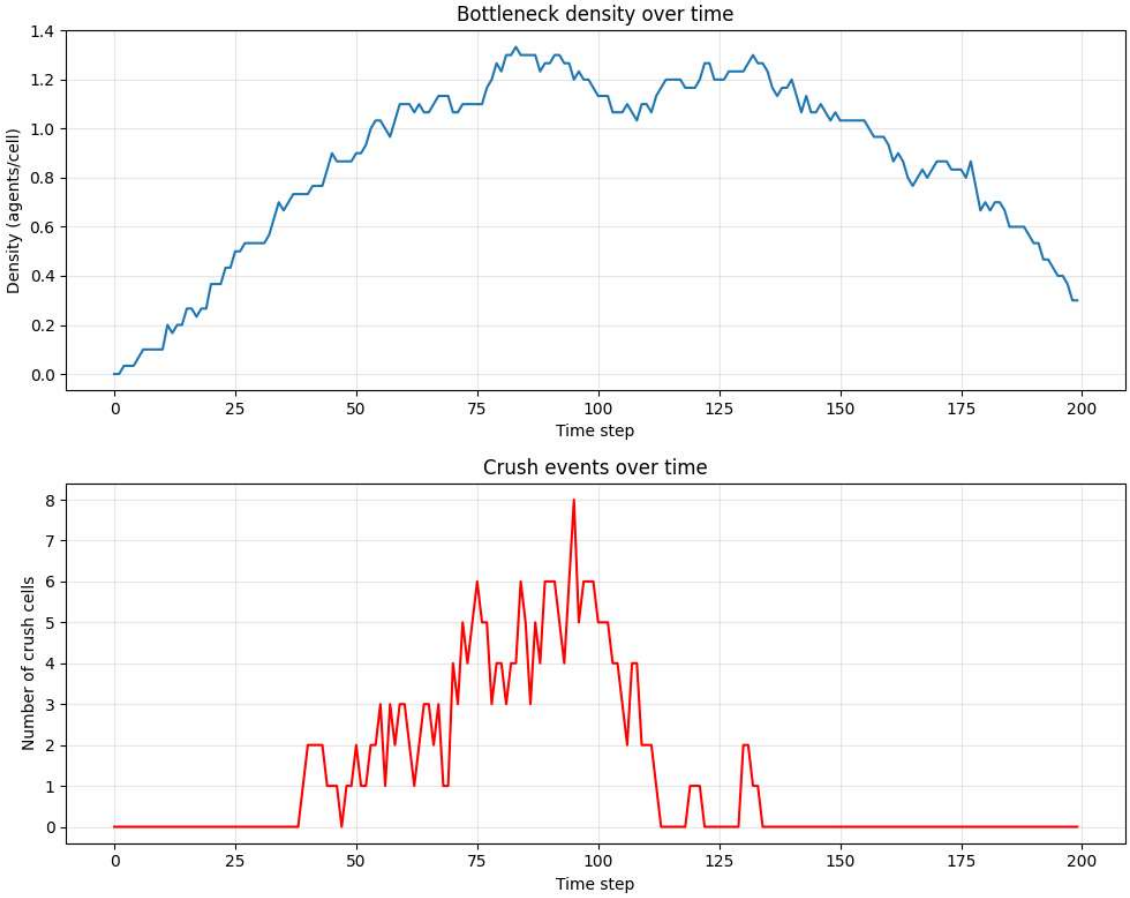
Sl. 5.4 Prikaz idućih ćelija sa Score. Konačna odluka će biti modelirana probabilistički gdje će najveću vjerojatnost imati ćelija sa najvećom Score varijablom

U slučaju da više agenata želi pristupiti istoj ćeliji moramo rješiti konflikt. U slučaju konflikta jedan agent dobiva pravo pomaka, dok ostali ostaju na prethodnoj poziciji.

```
for pos, agents in target_map.items():
            if len(agents) == 1:
                final_moves[agents[0]] = pos
            elif self.random.random() < 0.6:
                chosen = self.random.choice(agents)
                final_moves[chosen] = pos
        return final_moves
```

U slučaju da previše agenata budu u istoj ćeliji, označimo ju i ubrajamo u trenutke gdje se desio „crush event“. Broj agenata koji staje u jednu ćeliju određujemo mi. Ako uzmemo da je jedna ćelija jedan metar kvadratni, za kretanje je sigurna procjena oko 4 ljudi po ćeliji [5].

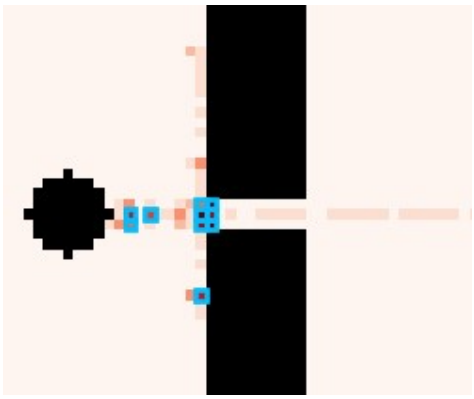
Konačno, pri izvršavanju sustava, prikazuju se korisni grafovi koji opisuju stanje gustoće i količinu kritičnih događaja u sustavu. Pomoću njih vidimo i uspoređujemo razne situacije i različite parametre.



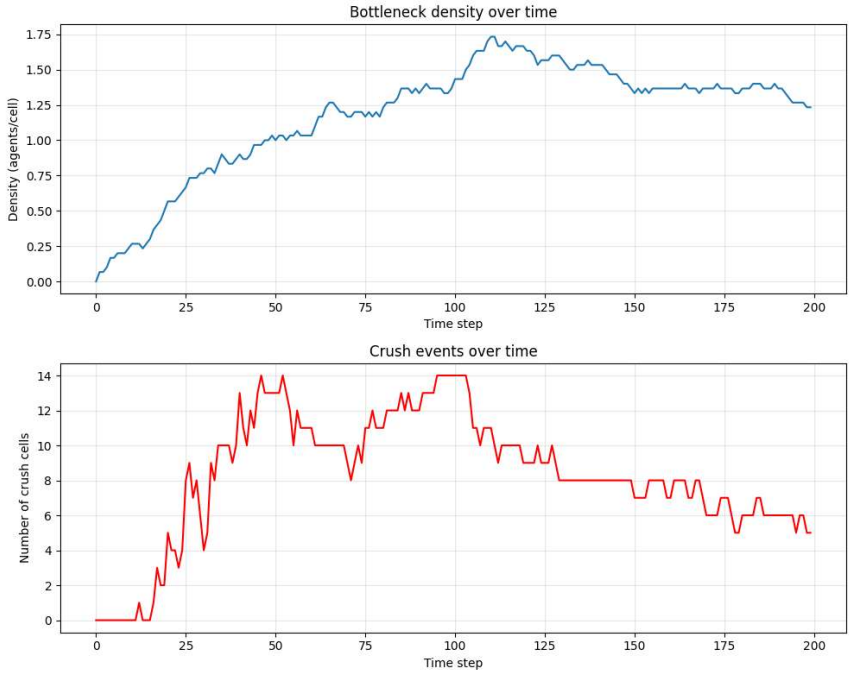
Sl. 5.5 Grafovi

6. Analiza rezultata

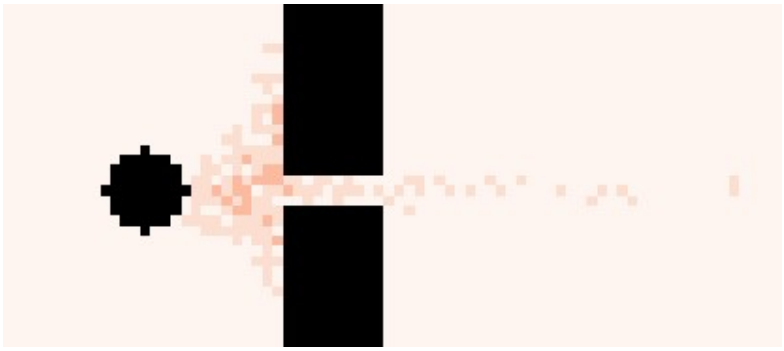
Pregledat ćemo interakcije faktora *kS* i *kD.* Primjetimo da su te dve karakteristike obrnuto proporcionalne. Ako imamo visoki faktor *kS* i niski *kD*, to bi bilo ekvivalentno žurnom kretanju bez obzira na dostupan prostor, te stvorilo veliki broj crush događaja. Desi se velika navala na otvorenje koridora i vrlo slab protok do izlaza.



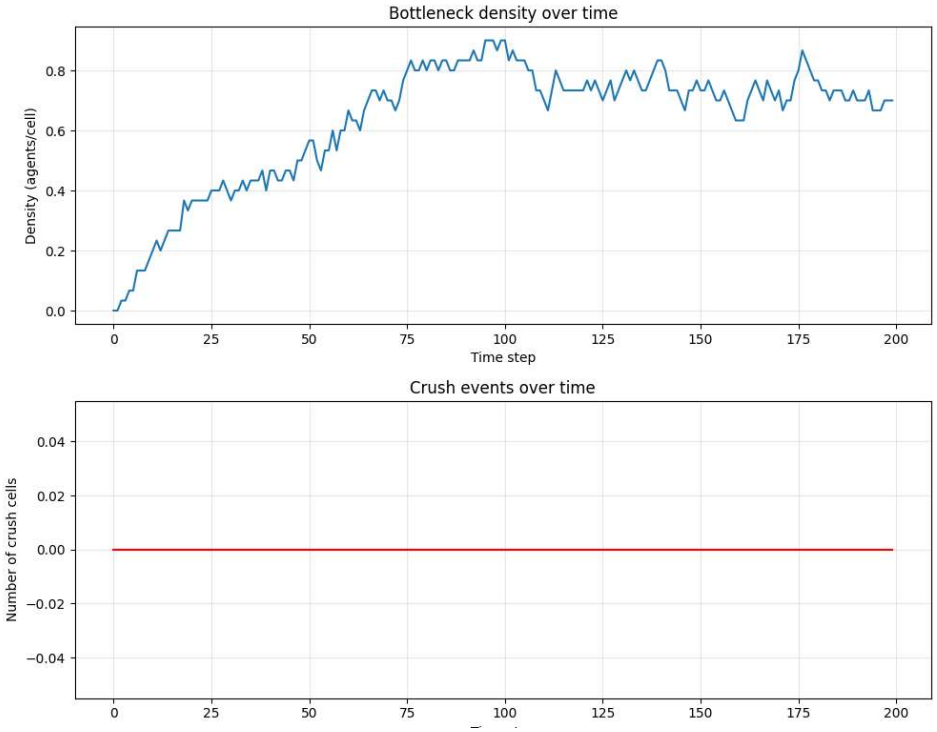
Sl. 6.1 kS = 8, kD = 2



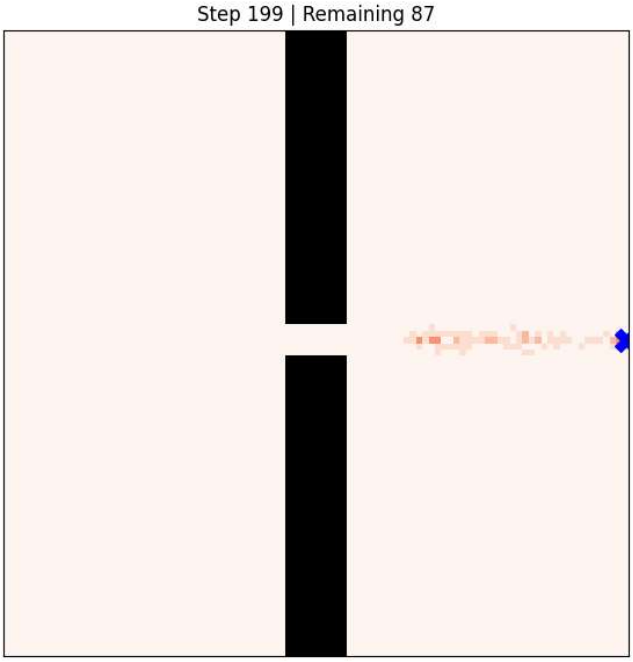
Druga situacija bi bila niski *kS* i visoki *kD*. U toj situaciji se ne dešava mnogo crush događaja, ako uopće. Jednostavno agenti mirno čekaju svoj red, to jest priliku da prođu kroz koridor.

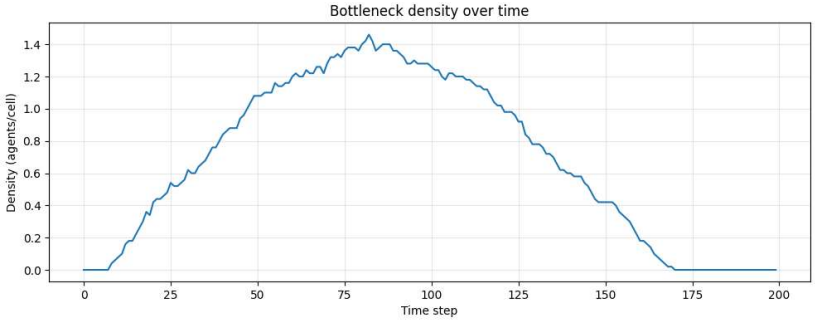


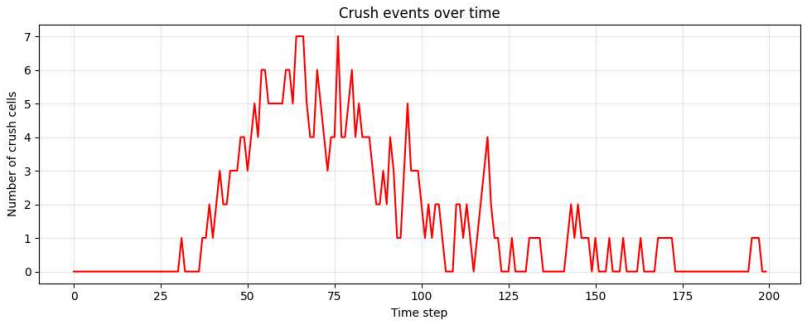
Sl. 6.2 kS = 2, kD = 8



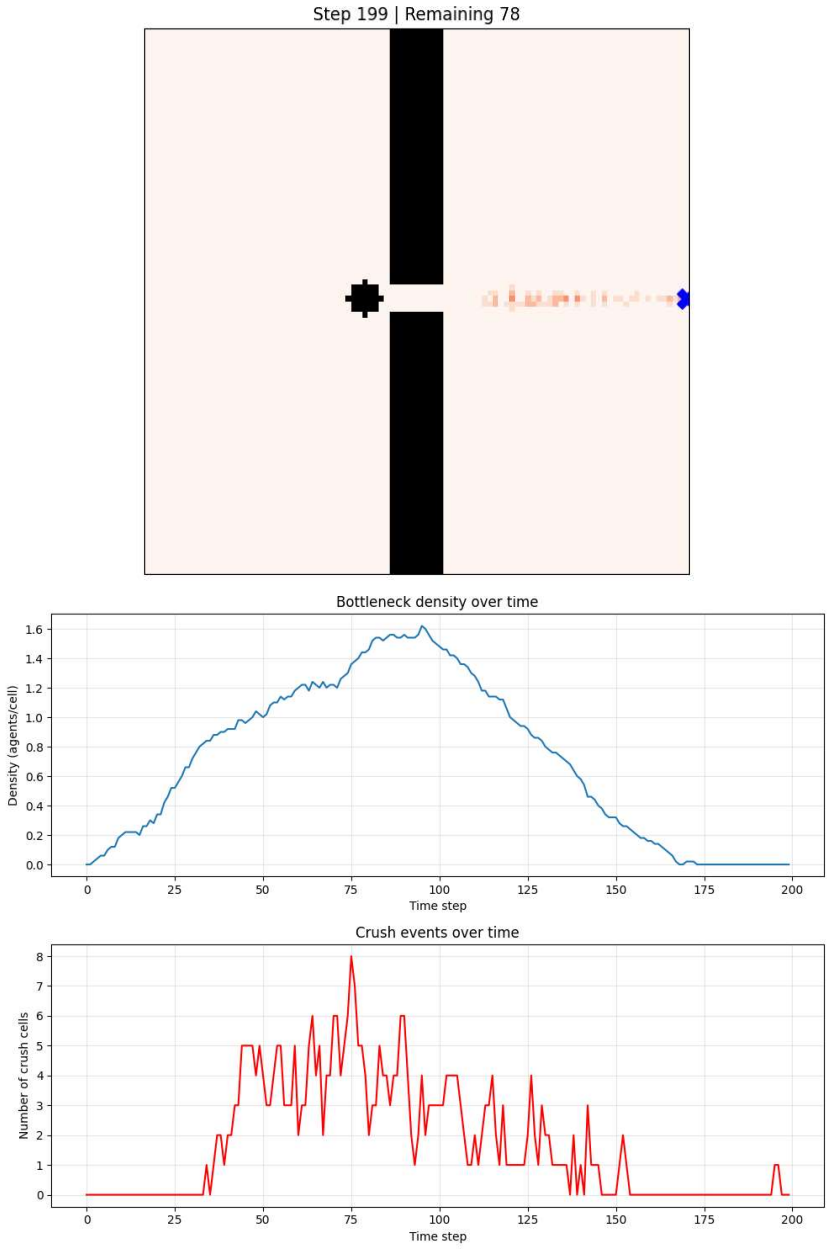
Proučimo ponašanje agenata ovisno o poziciji i veličini prepreke. Trenutna okrugla prepreka može pomoći, ali i odmoći disperziji agenata i poboljšanju protoka kroz koridor. U teoriji, cilj prepreke je da onemogući ulazak u uzak koridor sa mnogo strana odjednom, odnosno da napravi disperziju ulaska gdje su svi agenti prisilno postavljeni u red. Prvo definiramo početnu situaciju bez prepreke sa uravnoteženim faktorima *kS* i *kD*.



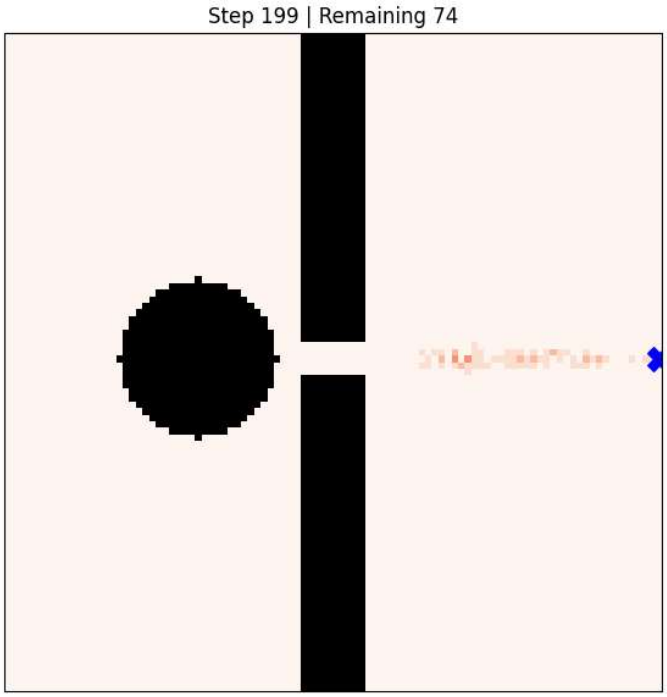


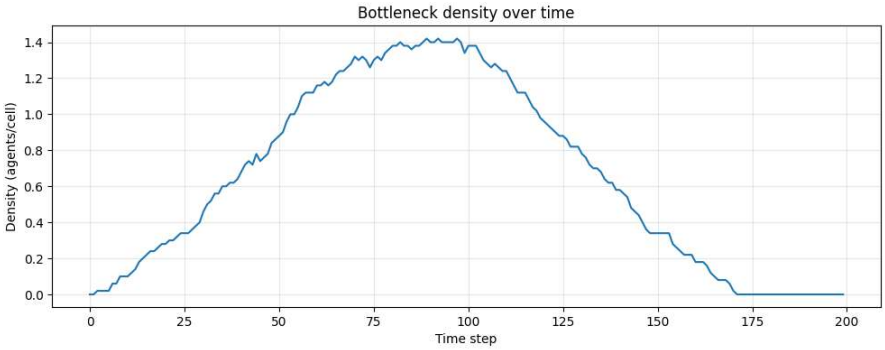


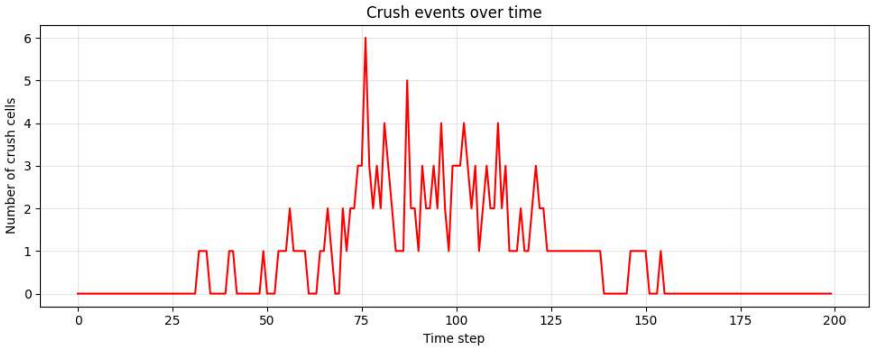
U 200 koraka, 113 agenata je uspjelo izaći iz sustava i grafovi prolaznosti su prikazani. Ako stavimo malu prepreku odmah ispred ulaska u koridor, situacija bude sljedeća:



Primijetimo nešto goru situaciju nego prethodno prikazano. No vidimo što se desilo. Prepreka ne čini puno da stvori disperziju ulaska u koridor, i desi se da ispred samog koridora se ponovo dešava naguravanje koje se u grafu vidi kao rano stvaranje crush događaja. Ponoviti ćemo situaciju sa puno većom barijerom.







Što se tiče crush događaja, situacija je puno bolja. Ukupnu količinu događaja možemo protumačiti kao površinu ispod crvenog grafa. Vidimo da je puno manje od inicijalnog bezpreprečnog sustava. I to je u slaganju sa našom inicijalnom teorijom. Poanta prepreke je da onemogući svima ravnomjernu brzinu izlaska, već da pokuša što bolje sve agente odvojiti kako bi u različitim trenucima došli do izlaza. Dodatno povećanje kruga daje i bolje rezultate.

7. Zaključak

Provedene simulacije pokazale su kako parametri modela i geometrija prostora imaju značajan utjecaj na ponašanje sustava, protočnost koridora i pojavu potencijalno opasnih zona visoke gustoće. Analizom različitih kombinacija parametara *kS* i *kD* potvrđeno je da odnos između želje agenata za ići prema izlazu i njihove osjetljivosti na lokalnu gustoću izravno određuje dinamiku gibanja populacije. To su u biti faktori kompromisa s kojima direktno prikazujemo „kriznost“ situacije i koliko brzo agenti žele izaći. U niskokriznim situacijama prepreke se pokazuju kao manje potrebne jer su ljudi osjetljivi na svoj osobni prostor i strpljivi da se ukaže prilika za pomak, dok u visokokriznim situacijama prepreke su ovelike potrebne jer bez njih se brzo može desiti zagušenje i stvaranje velikog pritiska na agente koji su zapeli u njemu.

Povećanjem dimenzija prepreke ostvarena je znatno bolja disperzija sustava i smanjenje ukupnog broja kritičnih događaja. Veća prepreka prisiljava agente na šire raspoređivanje prije ulaska u koridor, čime se smanjuje intenzitet lokalnog zagušenja i broj simultanih konflikata pri zauzimanju ćelija. Iako kružne prepreke mogu djelomično poboljšati protočnost sustava, postoje i učinkovitije geometrijske konfiguracije koje se koriste u stvarnim sustavima upravljanja velikog broja ljudi. Jedan od poznatih pristupa jest implementacija serpentinastih koridora koji prisilno razdvajaju i usporavaju tok ljudi prije dolaska do uskog prolaza. Takve konfiguracije koriste se primjerice u sustavima čekanja na aerodromima, stadionima i koncertnim prostorima. Njihova osnovna prednost jest postupno raspoređivanje ljudi u organizirane tokove manje gustoće, čime se smanjuje mogućnost naglog nakupljanja velikog broja ljudi ispred izlaza.

Postoje i faktori u stvarnome svijetu koji bi se mogli dodatno implementirati za poboljšane rezultate. Ponajprije to što nisu svi agenti građeni jednako i jednako osjetljivi na naguravanje.

Cellular automata pokazala se kao vrlo dobar pristup modeliranju kretnje većeg broja ljudi zbog jednostavne implementacije, računalne učinkovitosti i mogućnosti simulacije lokalnih konflikata, zagušenja i „crowd crush” situacija. Diskretna struktura prostora omogućuje jasnu analizu ponašanja agenata i utjecaja geometrije prostora na protočnost sustava. Ipak, postoje i napredniji pristupi poput modela socijalnih sila (Social Force Models) koji realističnije opisuju fizičke interakcije, prijenos sile i ponašanje mnoštva pri vrlo visokim gustoćama. Također, hibridni mikro-makroskopski modeli omogućuju detaljnije modeliranje velikih sustava uz manju računalnu složenost.

Unatoč tome, cellular automata modeli i dalje predstavljaju kvalitetan kompromis između realizma, brzine izvođenja i jednostavnosti implementacije.

8. Sažetak

Seminarski rad pokriva analizu izvedbe modela gužvi koristeći metodu cellular automata opisanu u odabranome članku. Objašnjenje i upotreba mikroskopskih modela za rješavanje problema gužvi u prostorima s izrazito velikom količinom ljudi s ciljem izbjegavanja mogućnosti katastrofe poput "crowd crush". Analiza mikroskopskih modela koji pristupaju problemu tako da simuliraju zasebno mnoštvo agenata koji međusobno sa svojim interakcijama prikazuju odnose i ponašanje ljudi u ograničenom prostoru. Metoda izvedbe, Cellular automata, definirani prostor prikazuje u obliku ćelija. Ćelije mogu biti prazne ili pune te stanje ćelije je direktno ovisno o njezinim susjedima. Navedene metode su implementirane u obliku računalne simulacije koja vizualizira mnoštvo ljudi, njihovu kretnju i potencijalne probleme koje mogu nastati s njom, s ciljem da rekreiramo rezultate prikazane u odabranome članku.

9. Literatura

[1] Wikipedia, »Crowd collapses and crushes,« [Mrežno]. Available: https://en.wikipedia.org/wiki/Crowd_collapses_and_crushes.

[2] J. G. A. W. M.-T. FISCHER MICHAEL, *MICRO- AND MACROSCOPIC MODELING OF CROWDING AND PUSHING IN CORRIDORS,* 2020.

[3] Wolfram Mathworld, »Cellular Automaton,« [Mrežno]. Available: https://mathworld.wolfram.com/CellularAutomaton.html.

[4] »Mesa: Agent-based modeling in Python,« [Mrežno]. Available: https://mesa.readthedocs.io/stable/.

[5] P. D. G. K. Still, »Static crowd density,« [Mrežno]. Available: https://www.gkstill.com/Support/crowd-density/CrowdDensity-1.html.